Оценка неопределенности в задачах классификации

Докладчик: Едакина Мария Вадимовна
Авторы: Gal & Ghahramani — 'Dropout as a Bayesian Approximation' (ICML 2016)

Долгопрудный, 2026

Почему неопределенность важна?

Безопасность

Критические области (медицина, автономные системы) требуют понимания, когда доверять системе, а когда нет.

Проблема уверенности

Современные модели могут быть очень уверены, но при этом ошибаются.

Индукция

Машинное обучение строится на индукции — модель и предсказание не могут быть доказаны.

Рис. 1: Прогнозы EfficientNet (Tan и Le, 2019) на тестовых изображениях из ImageNet: для левого изображения нейронная сеть предсказывает “клавиатуру пишущей машинки” с достоверностью 83,14%, для правого изображения “каменную стену” с достоверностью 87,63%. [1]

Два типа неопределенности

Полная неопределенность

Алеаторная

Неустранимый шум/случайность в генерации данных, который остается даже в идеальной модели.

Пример: подбрасывание честной монеты.

Эпистемическая

Нехватка данных о лучшей модели/гипотезе, может быть уменьшена с помощью дополнительной информации.

Пример: незнание слова.

$$\underbrace{\mathrm{MI}(y,\, \boldsymbol{\theta} \mid \mathcal{D},\, \mathbf{x})}_{\text{Epistemic Uncertainty}} = \underbrace{\mathcal{H}_{y \sim p(y|\mathbf{x},\, \mathcal{D})}[y]}_{\text{Total Uncertainty}} - \underbrace{\mathbb{E}_{p(\boldsymbol{\theta}|\mathcal{D})}\left[\, \mathcal{H}_{y \sim p(y|\mathbf{x},\, \boldsymbol{\theta})}[y] \,\right]}_{\text{Aleatoric Uncertainty}}$$

Байесовский подход

- Задать априорное распределение $p(\theta)$, из которого вычислить апостериорное $p(\theta|D)$.

$$\theta \sim p(\theta), \qquad p(\theta \mid D) = \frac{p(D \mid \theta)\, p(\theta)}{p(D)}$$

- Предсказательное распределение моделируется:

$$p(y \mid x, D) = \int_\theta p(y \mid x, \theta)\, p(\theta \mid D)\, \mathrm{d}\theta\,, \qquad p(D) = \int p(D|\theta)\, p(\theta)\, d\theta$$

- Вычислить апостериорное распределение сложно из-за $p(D)$, для упрощения используется вариационный метод:

$$p(\theta \mid D) \sim \mathrm{q}(\theta), \qquad p(y \mid x, D) \approx \int_\theta p(y \mid x, \theta)\, q(\theta)\, \mathrm{d}\theta \approx \frac{1}{\mathrm{M}} \sum_{l=1}^{\mathrm{M}} p(y \mid x, \theta_l)\,, \qquad \theta_l \sim q(\theta)$$

Monte Carlo Dropout

- Можно показать, что нейронная сеть, обученная с применением дропаута, аппроксимирует апостериорное распределение $p(\theta \mid D)$. Для получения выборок из $q(\theta)$ достаточно использовать сеть с активным дропаутом. [1]
- Алгоритм:
    1. Обучить сеть с дропаутом.
    2. Во время предсказаний не выключать дропаут.
    3. Сделать M стохастических проходов, из которых можно получить M разных предсказаний.
    4. Вычислить все неопределенности

Постановка эксперимента

- Задача: Бинарная классификация одномерных данных.

- Данные:
  Класс 0: x ∈ [-5, -3] ∪ [1, 2.5]
  Класс 1: x ∈ [-3,-2] ∪ [2.5, 5]
  Пустая область: x ∈ (-1, 1)

- Модель:
  4-слойный MLP, активация Sigmoid $\sigma(x) = \frac{1}{1+e^{-x}}$
  Dropout p = 0.2
  4000 эпох, Adam и OneCycleLR

- MC Dropout:
  M = 100 проходов вперёд

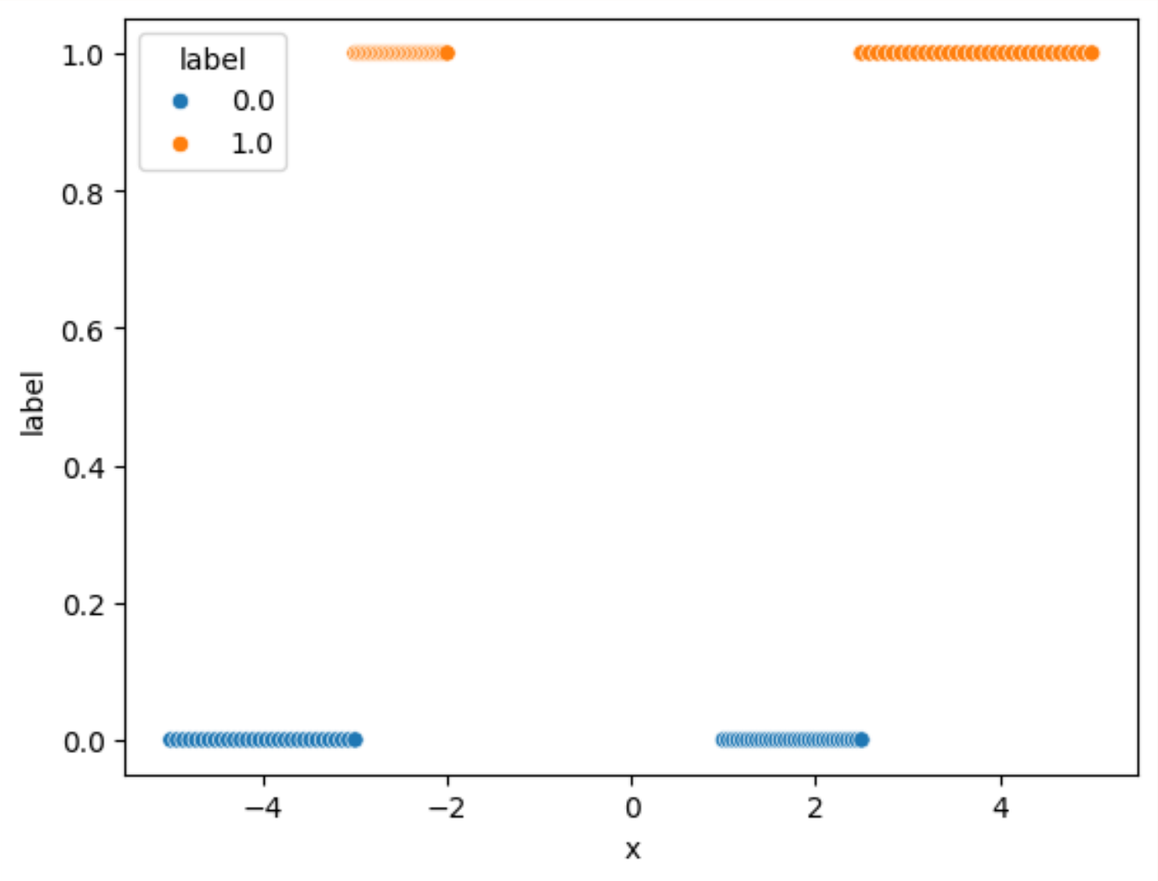

Рис. 2: Обучающая выборка — два класса с перекрывающимися границами: класс 0 (синий) и класс 1 (оранжевый)

Результаты: предсказание MC Dropout

- Тонкие голубые линии: отдельные предсказания $p(y \mid x, \theta_l)$ при каждом проходе с дропаутом.
- Красная линия: итоговое предсказание $p(y \mid x, D)$, среднее по всем прогонам.
- Голубая линия: предсказание, если бы дропаут был выключен.

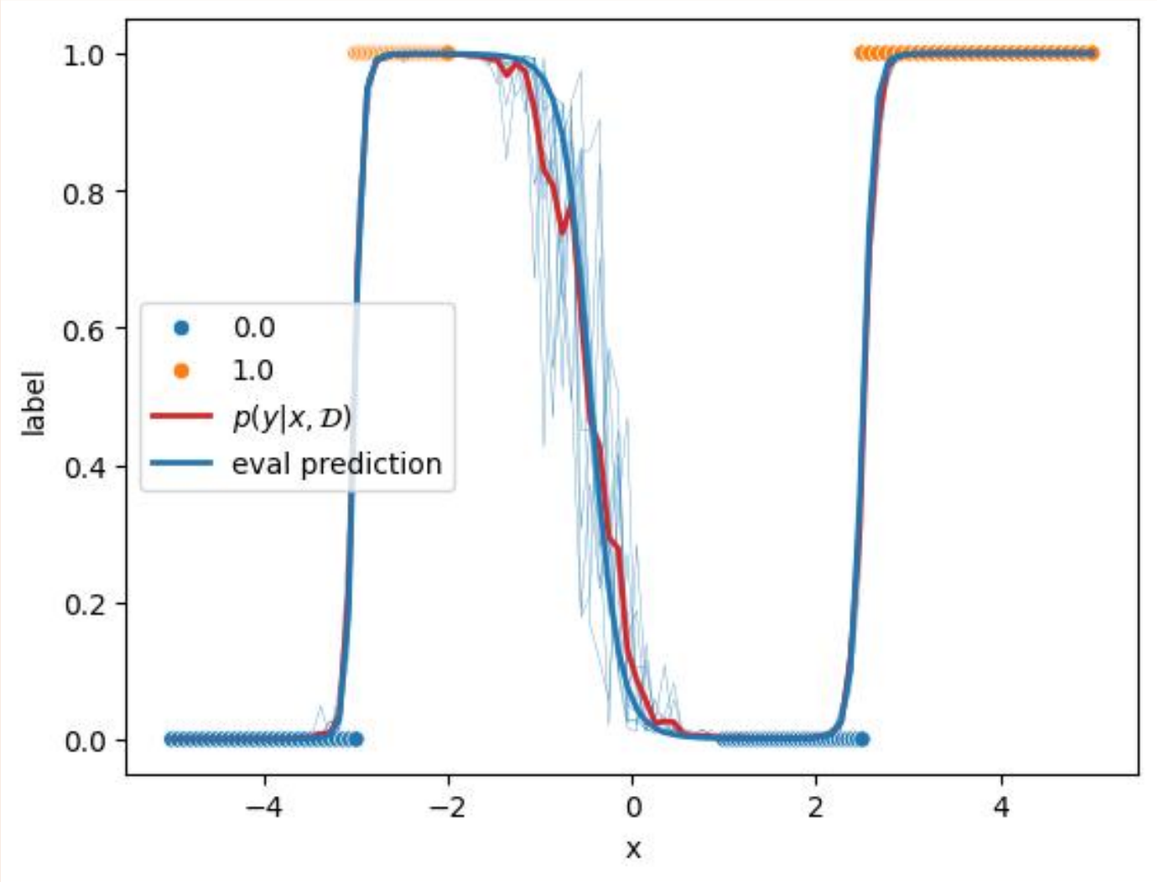

Рис. 3: Предсказания MC Dropout — 100 стохастических проходов (голубые линии), среднее при MC Dropout (красная линия) и предсказание (синяя линия)

Результаты: разделение неопределенности

- Алеаторная: $x \approx -3,\ 2.5$ — границы классов, перекрытие в данных.
- Эпистемическая: $x \in [-1,\ +1]$ — область, где модель не видела данных.

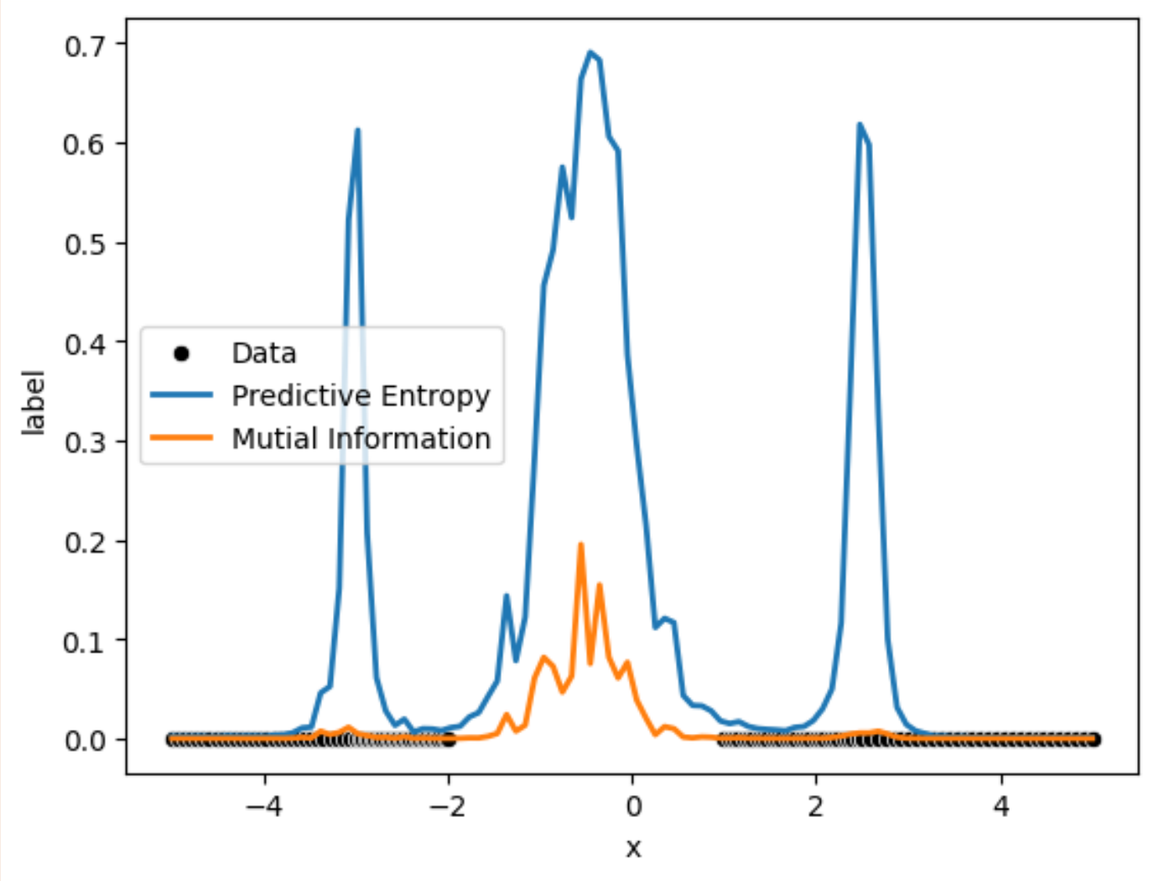

Рис. 4: Разделение неопределённости — полная неопределенность (синяя) и взаимная информация (оранжевая)

Заключение и выводы

- Неопределенность состоит из двух частей: алеаторной (шум данных, неустранима) и эпистемической (незнание модели, устранима).
- Байесовский подход позволяет оценивать неопределенность и разделять ее.
- Метод Monte Carlo Dropout позволяет аппроксимировать апостериорное распределение без изменения архитектуры сети.

Ссылка на Github с кодом

Список литературы

[1] Hüllermeier E., Waegeman W. *Aleatoric and Epistemic Uncertainty in Machine Learning: An Introduction to Concepts and Methods.* arXiv:1910.09457, 2020.
[2] Gal Y., Ghahramani Z. *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning.* ICML 2016, PMLR 48:1050–1059.

Спасибо за внимание!

Контакты: @mashakina
edakina.mv@phystech.edu